

Relatório – Adoção de Telemedicina no Medicare

Alunos:

GUSTAVO BEZERRA ASSUMÇÃO – RM553076

Gilson Dias Ramos Junior – RM552345

Jeferson Gabriel de Mendonça – RM553149

LARISSA ESTELLA GONÇALVES DOS SANTOS – RM552695

Previsão de Alta Adoção de Telemedicina no Medicare

Este relatório analisa a adoção de telemedicina entre beneficiários do Medicare nos Estados Unidos, com base no conjunto de dados Medicare Telehealth Trends, disponibilizado pelo Centers for Medicare & Medicaid Services (CMS). O foco é compreender como características regionais, demográficas e o histórico recente de utilização se relacionam com a intensidade de uso de consultas remotas ao longo do tempo e, principalmente, avaliar se essas características permitem antecipar quais combinações de estado, trimestre e grupo populacional tendem a apresentar níveis mais elevados de utilização de telehealth.

A pergunta central que orienta o trabalho é a seguinte: até que ponto é possível prever, a partir de atributos regionais, demográficos e do histórico recente de uso, quais estados e grupos do Medicare estarão entre os segmentos de alta adoção de telemedicina em um determinado trimestre, de forma útil para priorização de políticas públicas e ações de gestão? Todas as etapas – descrição dos dados, análise exploratória, formulação do modelo de classificação, avaliação de desempenho e discussão de limitações – são organizadas em torno dessa pergunta.

O objetivo não é apenas produzir um modelo com bom desempenho numérico, mas entender quais padrões se mantêm entre trimestres, quais grupos se destacam de forma consistente e em que medida o modelo pode apoiar decisões concretas: por exemplo, escolher quais estados e segmentos devem receber campanhas específicas, recursos adicionais ou monitoramento mais próximo em cenários de restrição orçamentária.

1. Dados e construção da variável-alvo

O conjunto de dados utilizado foi extraído do painel público Medicare Telehealth Trends, disponível no portal de dados do CMS. Cada linha representa uma combinação de estado ou nível nacional (Bene_Geo_Desc), trimestre (campos Year e quarter) e recortes demográficos formados por idade, sexo, raça/etnia (RTI), status de elegibilidade (apenas Medicare ou Medicare & Medicaid) e tipo de benefício (Aged, Disabled ou ESRD). Para cada combinação, são fornecidas contagens de beneficiários elegíveis, contagens de beneficiários que utilizaram telehealth e a porcentagem de telehealth (Pct_Telehealth).

Neste estudo, a unidade de análise foi definida como Estado $\times$ Trimestre $\times$ Grupo demográfico. O horizonte temporal considerado abrange o período de 2020-Q1 a 2025-Q1, de modo a capturar o choque inicial da pandemia de COVID-19, a fase de ajuste regulatório e a estabilização de uso em patamares pós-pandemia.

A variável-chave do trabalho é Pct_Telehealth, que mede a proporção de beneficiários que tiveram pelo menos um atendimento remoto no período. A partir dessa medida, foi construída uma variável-alvo binária para formulação do problema de aprendizagem de máquina. Em cada trimestre, as observações foram ordenadas por Pct_Telehealth e definimos como Alta Adoção (classe 1) o conjunto de combinações Estado $\times$ grupo demográfico que pertencem ao percentil superior (aproximadamente os 25% maiores valores). As demais observações foram rotuladas como Baixa Adoção (classe 0). Esse procedimento reduz o viés introduzido por variações estruturais ao longo do tempo, concentrando a atenção em quem está relativamente mais à frente em cada trimestre.

O resultado é um problema de classificação binária moderadamente desbalanceado: a classe Alta Adoção reúne cerca de um quarto das observações por trimestre, enquanto a classe Baixa Adoção concentra os três quartos restantes. Esse desbalanceamento orienta, como se discutirá adiante, a escolha de métricas (como ROC e Precision–Recall) mais informativas do que a simples acurácia.

2. Análise exploratória: evolução temporal e padrão urbano–rural

A primeira etapa consistiu em examinar a evolução temporal da porcentagem de telehealth no nível nacional, bem como as diferenças entre áreas urbanas e rurais segundo a classificação RUCA. A Figura 1 apresenta, à esquerda, a série temporal nacional de Pct_Telehealth entre 2020-Q1 e 2025-Q1. Observa-se um salto abrupto de aproximadamente 7% em 2020-Q1 para cerca de 47% em 2020-Q2, refletindo a migração emergencial para consultas remotas durante o pico inicial da pandemia. Em seguida, há um recuo para a faixa de 28% em 2020-Q3 e 2020-Q4 e, a partir de 2022, a série se estabiliza em patamares entre 13% e 15%.

No painel direito, a mesma figura segmenta o comportamento por áreas urbanas e rurais. As regiões urbanas apresentam percentuais sistematicamente mais elevados, oscilando entre 15% e 17% na fase de estabilização pós-2022, enquanto as áreas rurais permanecem em torno de 10% a 13%. Ou seja, mesmo após a fase aguda da pandemia, persiste um gap de aproximadamente 3–5 pontos percentuais entre ambientes urbanos e rurais. Esse padrão sugere que a variável indicadora “Urbano vs Rural” deve carregar poder explicativo relevante para distinguir segmentos de alta adoção, hipótese que será verificada na etapa de modelagem.




Figura 1 – Séries temporais de % Telehealth no nível nacional e por classificação RUCA (urbano vs rural).

3. Distribuições gerais e diferenças estruturais

Para entender se a adoção de telehealth está concentrada em poucos segmentos ou distribuída de forma mais homogênea, analisou-se a distribuição completa de Pct_Telehealth e as diferenças urbano–rural em termos de dispersão. A Figura 2, à esquerda, mostra o histograma geral: a maior parte das observações concentra-se entre 5% e 25%, com cauda longa que se estende até valores próximos de 60–70%. Esse formato assimétrico indica que existem grupos muito acima da média, ainda que em quantidade relativamente pequena.

À direita, o boxplot de Pct_Telehealth segmentado por RUCA confirma que áreas urbanas não apenas têm mediana mais alta, mas também maior variabilidade, com outliers em níveis bastante elevados. Em contraste, as regiões rurais apresentam mediana menor e menos observações extremas. Do ponto de vista de modelagem, essa assimetria e a presença de valores extremos reforçam a decisão de trabalhar com métricas robustas (ROC e Precision–Recall) e de empregar técnicas de regularização para evitar que poucos pontos influenciem de maneira desproporcional o ajuste do modelo.




Figura 2 – Histograma geral de % Telehealth e boxplot por RUCA (urbano vs rural).

4. Recortes demográficos e status de elegibilidade

Além do recorte geográfico, foram examinados os padrões de telehealth por idade, sexo, raça/etnia e status de elegibilidade no trimestre mais recente (2025-Q1). A Figura 3 resume as médias nacionais por faixa etária, sexo e grupos raciais. Observa-se que o grupo de 0–64 anos apresenta aproximadamente 27% de telehealth, enquanto as faixas de 65–74, 75–84 e 85+ situam-se em torno de 11–13%. Em termos práticos, beneficiários mais jovens dentro do universo do Medicare – muitos deles provavelmente elegíveis por invalidez – exibem adoção significativamente maior do que os mais idosos.

No eixo racial, grupos Hispanic e Asian/Pacific Islander situam-se ligeiramente acima da média nacional, enquanto Non-Hispanic White e American Indian/Alaska Native aparecem com percentuais menores. Ainda que as diferenças não sejam tão acentuadas quanto nos recortes etários, elas sugerem variações culturais, econômicas e de acesso que podem influenciar a propensão ao uso de telehealth. No modelo, essas categorias são representadas por variáveis binárias, de modo que sua contribuição para a probabilidade de Alta Adoção pode ser quantificada.




Figura 3 – % Telehealth por faixa etária, sexo e raça/etnia no nível nacional (2025-Q1).

A Figura 4 aprofunda a análise ao considerar o status de elegibilidade. Beneficiários com cobertura combinada Medicare & Medicaid apresentam média de telehealth superior (cerca de 23%) àqueles com apenas Medicare (aproximadamente 11%). Quando se observa o tipo de benefício, grupos Disabled e ESRD aparecem com percentuais próximos ou superiores a 20%, enquanto o grupo Aged permanece na casa de 12–13%. Esses achados reforçam a interpretação de que condições de saúde mais complexas e maior vulnerabilidade socioeconômica estão associadas a maior uso de telemedicine, possivelmente por necessidade de acompanhamento frequente e por barreiras de mobilidade.

Do ponto de vista da pergunta central, esses recortes demográficos e de elegibilidade são candidatos naturais a preditores da classe Alta Adoção. A hipótese de trabalho é que a combinação de perfil demográfico mais vulnerável com estado e contexto urbano que

oferecem infraestrutura adequada tende a produzir probabilidades elevadas de telehealth, o que será testado na fase de modelagem.




Figura 4 – % Telehealth por status de elegibilidade (Medicare & Medicaid vs Medicare only) e tipo de benefício (Aged, Disabled, ESRD).

5. Heterogeneidade entre estados e correlação entre variáveis

No nível de estados, a Figura 5 mostra os dez estados com menor e maior % de telehealth em 2025-Q1. No topo aparecem California, District of Columbia, Massachusetts, Hawaii e New York, todos com percentuais substancialmente superiores à média nacional. Na base, encontram-se Territories, Virgin Islands, Alabama, Iowa, Nebraska, North Dakota e South Dakota, entre outros, com valores bem abaixo da média. Essa disparidade revela um padrão consistente: estados mais urbanizados, com maior densidade de prestadores e infraestrutura digital, tendem a liderar a adoção, enquanto regiões predominantemente rurais ou economicamente menos dinâmicas permanecem na retaguarda.

Embora o modelo trate o estado como variável categórica (codificada via one-hot encoding), a leitura da Figura 5 é importante para contextualizar as previsões. Mesmo que a classificação Alta vs Baixa Adoção seja feita em termos relativos por trimestre, a persistência de certos estados nas extremidades da distribuição indica que há fatores não observados – como políticas locais e redes de prestadores – influenciando o padrão de telehealth.




Figura 5 – Top 10 e Bottom 10 estados em % Telehealth no trimestre 2025-Q1.

A Figura 6 apresenta o heatmap de correlação entre variáveis numéricas agregadas. Observa-se um bloco de correlação muito alta entre `Total_Bene_TH_Elig`, `Total_PartB_Enrl` e `Total_Bene_Telehealth`, o que é esperado, pois tratam de contagens de populações relacionadas. A correlação entre essas contagens e `Pct_Telehealth` é moderada: variações na porcentagem de telehealth não são explicadas apenas pelo tamanho da população elegível, o que abre espaço para o papel de fatores estruturais e demográficos.

A redundância entre variáveis de contagem motivou o uso de padronização e regularização na etapa de modelagem. Ao penalizar coeficientes excessivamente grandes em colunas fortemente correlacionadas, a regularização reduz o risco de instabilidade numérica e ajuda a concentrar o aprendizado em padrões mais gerais, coerentes com a pergunta central de previsão.




Figura 6 – Heatmap de correlação entre variáveis numéricas selecionadas.

6. Formulação do modelo de classificação

Com base nos achados exploratórios, o problema foi formalizado como uma tarefa de classificação binária em que o objetivo é prever se uma combinação Estado × Trimestre × Grupo demográfico pertence à classe Alta Adoção (top 25% de Pct_Telehealth no trimestre) ou à classe Baixa Adoção. As variáveis preditoras utilizadas no modelo final incluem:

- Ano (Year) e trimestre (quarter), como variáveis numéricas;
- Taxa de elegibilidade para telehealth (elig_rate), definida como a razão entre beneficiários elegíveis e total de beneficiários Part B;
- Pct_Telehealth defasado em um trimestre (pct_lag1), isto é, a porcentagem de telehealth do trimestre imediatamente anterior para o mesmo estado;
- Variáveis categóricas de interesse (estado, RUCA, faixas etárias, sexo, grupos de raça/etnia, status de elegibilidade e tipo de benefício), em análises complementares e em modelos alternativos.

Para evitar vazamento de informação, a variável Pct_Telehealth do trimestre corrente não foi utilizada diretamente como preditora. Em seu lugar, foi criada a feature pct_lag1, que representa a porcentagem de telehealth do trimestre anterior para o mesmo estado. Dessa forma, o modelo utiliza apenas informação historicamente disponível no momento da previsão, alinhando-se a um cenário prospectivo realista.

As análises de desempenho indicam que `pct_lag1` é, em geral, o preditor mais influente sobre a probabilidade de alta adoção, refletindo a forte inércia temporal na utilização de telehealth: estados e grupos que já estavam na fronteira de uso tendem a permanecer à frente. As variáveis regionais e demográficas modulam esse efeito, diferenciando situações em que o histórico elevado se mantém (por exemplo, em estados urbanos com alta proporção de beneficiários Disabled ou ESRD) daquelas em que a adoção tende a se reduzir ou a crescer mais lentamente.

O conjunto de dados foi dividido temporalmente: observações de 2020-Q2 a 2023-Q4 foram utilizadas para treino, o ano de 2024 serviu como conjunto de validação e o trimestre 2025-Q1 foi reservado como teste prospectivo. Essa estratégia reduz o risco de vazamento temporal e simula o cenário em que o gestor precisa tomar decisões para um período futuro com base apenas em dados históricos.

Foram considerados dois modelos principais. O primeiro é uma Regressão Logística com regularização (penalização L2), que serve como baseline interpretável e lida bem com multicolinearidade entre variáveis numéricas. O segundo é um modelo de HistGradientBoosting, capaz de capturar interações não lineares entre variáveis e de adaptar-se a distribuições assimétricas. Ambos são encapsulados em pipelines que incluem pré-processamento (codificação categórica e padronização, quando aplicável), assegurando que o fluxo de dados seja reprodutível e evitando diferenças de tratamento entre treino e teste.

7. Desempenho do modelo e capacidade preditiva

A avaliação do modelo no conjunto de validação (ano de 2024) e no conjunto de teste (2025-Q1) utiliza métricas adequadas a problemas desbalanceados. A Tabela 1 resume os principais indicadores de desempenho para a classe de Alta Adoção (classe 1).

Conjunto	AUC ROC	AP	F1 (classe 1)	Precisão (classe 1)	Recall (classe 1)
Validação 2024	0,977	0,941	0,836	0,718	1,00
Teste 2025-Q1	0,986	0,964	0,609	0,438	1,00

Tabela 1 – Métricas de desempenho do modelo para a classe de Alta Adoção.

Os resultados indicam que o classificador consegue separar com alto grau de confiança os segmentos de alta e baixa adoção. O recall igual a 1,0, tanto na validação quanto no teste, significa que praticamente todos os segmentos de Alta Adoção foram identificados pelo modelo (ausência de falsos negativos relevantes). A precisão mais baixa, especialmente no teste (0,438), indica que parte dos segmentos apontados como de alta adoção na verdade pertence à classe Baixa Adoção. Esse trade-off é aceitável no contexto do problema, em que é

mais crítico não deixar de priorizar segmentos realmente avançados do que evitar totalmente falsos positivos.

A Figura 7 exibe as curvas ROC e Precision-Recall para o conjunto de teste. A área sob a curva ROC (AUC) de 0,986 indica que, ao comparar aleatoriamente um par de observações (uma de Alta Adoção e outra de Baixa Adoção), o modelo atribui pontuação maior à observação positiva em aproximadamente 98,6% dos casos. A área sob a curva Precision-Recall (AP), de 0,964, reforça que o modelo mantém bom desempenho mesmo considerando o desbalanceamento entre as classes.




Figura 7 – Curvas ROC e Precision-Recall no conjunto de teste (2025-Q1).

Para além das curvas de discriminação, é importante avaliar a calibração das probabilidades previstas. A Figura 8 (painel esquerdo) mostra a relação entre as probabilidades médias em cada faixa de score e a frequência observada da classe Alta Adoção. Nas faixas de probabilidade mais altas, o modelo apresenta calibração razoavelmente próxima da diagonal ideal, o que sugere que, ao prever 80–90% de chance de alta adoção para um grupo, a proporção real de casos positivos é compatível com esse valor.

O painel direito apresenta a curva de Lift cumulativo. Quando as observações são ordenadas pelo score do modelo e se considera, por exemplo, o decil superior (10% com maior probabilidade prevista), observa-se um ganho de aproximadamente 3 vezes em relação à seleção aleatória. Em termos da pergunta central, isso significa que o modelo é efetivo para priorizar segmentos do Medicare que tendem a estar na fronteira de alta adoção, permitindo que gestores concentrem esforços em um subconjunto reduzido de estados e grupos demográficos com retorno esperado muito maior.




Figura 8 – Curva de calibração e curva de Lift cumulativo no conjunto de teste.

8. Interpretação, limitações e implicações para política pública

À luz dos resultados, a pergunta central pode ser respondida de forma afirmativa, ainda que com ressalvas. As combinações de Estado, contexto urbano–rural, perfis demográficos e histórico recente de utilização capturam boa parte da variabilidade na adoção de telehealth, o que permite prever, com alta precisão, quais segmentos estarão no grupo de Alta Adoção em trimestre futuro e, portanto, priorizar ações de gestão. Em particular, o modelo identifica com consistência como candidatos à alta adoção: estados mais urbanizados e economicamente dinâmicos; grupos mais jovens dentro do universo do Medicare; e beneficiários Disabled, ESRD e dual-eligible (Medicare & Medicaid).

Contudo, esses mesmos padrões levantam um alerta importante. Como o modelo aprende a partir de dados históricos, ele tende a reproduzir desigualdades estruturais: se estados e grupos vulneráveis tiveram, no passado, menor acesso a infraestrutura digital ou menor incentivo institucional ao uso de telehealth, é provável que a probabilidade prevista de Alta Adoção nesses segmentos continue baixa. Usar o modelo apenas para priorizar quem já está na frente pode reforçar desigualdades, em vez de corrigi-las.

Além disso, o estudo apresenta limitações de escopo e de dados. Variáveis diretamente relacionadas à oferta de infraestrutura – como densidade de provedores, número de clínicas com capacidade de telehealth ou indicadores de conectividade de banda larga – não estão presentes no conjunto original. Tampouco há informação sobre desfechos clínicos, satisfação do paciente ou custos associados a cada tipo de atendimento. Como consequência, o modelo captura essencialmente padrões de utilização, e não necessariamente de valor ou eficiência em saúde.

Do ponto de vista metodológico, embora a divisão temporal treino–validação–teste reduza a chance de superestimar o desempenho, uma avaliação mais robusta poderia incluir múltiplos períodos futuros e análises de sensibilidade em relação à definição do limiar de

Alta Adoção (por exemplo, top 20% ou 30%). Também seria desejável aprofundar a análise de importância de variáveis, seja por meio de coeficientes da Regressão Logística, seja por técnicas de permutation importance no modelo de gradiente, de modo a quantificar de forma mais explícita a contribuição de cada fator.

Em síntese, os resultados indicam que é possível prever com alta precisão quais segmentos do Medicare estarão entre os grupos de alta adoção de telemedicina em um trimestre futuro, usando características regionais, demográficas e histórico recente de utilização. No entanto, qualquer aplicação prática desses modelos deve ser acompanhada de uma reflexão explícita sobre objetivos de equidade e sobre o risco de reforço de desigualdades preexistentes. A utilidade real do modelo não está apenas em prever o futuro, mas em informar estratégias que combinem eficiência alocativa com compromisso com a redução de gaps de acesso em saúde digital.

Principais insights extraídos da análise:

- Estados como California, District of Columbia, Massachusetts, Hawaii e New York formam um núcleo persistente de alta adoção de telehealth, associado a contextos mais urbanos e com maior disponibilidade de infraestrutura digital.
- Grupos 0–64 anos, beneficiários Disabled e ESRD, bem como dual-eligibles (Medicare & Medicaid), apresentam níveis de utilização consistentemente superiores à média, refletindo maior necessidade de acompanhamento e barreiras de mobilidade mais relevantes.
- O histórico recente de utilização (pct_lag1) é o preditor isolado mais forte de alta adoção, enquanto variáveis regionais e demográficas modulam esse histórico, indicando em quais contextos a telemedicina tende a se consolidar ou a perder espaço ao longo do tempo.
- A priorização de segmentos com base no score do modelo – por exemplo, o decil superior de probabilidade – pode multiplicar por três a concentração de grupos de alta adoção em ações de política pública, desde que acompanhada de critérios explícitos de equidade para não aprofundar disparidades existentes.